Formlist

Comparateur indépendant de formations e-commerce
Dossier technique et produit

État au 4 août 2026 · 232 fiches · 163 organismes · 2 716 informations vérifiées
Document généré depuis le dépôt — les chiffres sont lus dans le catalogue, pas recopiés.

1. Ce que le produit est

Aider quelqu'un à trouver la formation e-commerce adaptée à sa situation en comparant des **faits vérifiables**. Pas en lui disant laquelle est la meilleure.

Le marché français est dominé par des comparatifs rémunérés à l'affiliation. Le pari de Formlist est l'inverse : ne rien noter, ne rien classer par qualité, ne toucher aucune commission, et tirer sa valeur de l'exhaustivité du catalogue et de la vérifiabilité de chaque information.

232
parcours au catalogue

163
organismes

2 716
informations vérifiées

1 369
champs non encore collectés

6
fiches vérifiées en profondeur

Les huit invariants

1. Aucune note, aucun score de qualité, aucune moyenne. Nulle part.
2. Aucune information déduite. Un champ inconnu s'affiche « Non communiqué ».
3. Une fiche incomplète n'est jamais retirée du catalogue.
4. Le tri décrit l'état des fiches, jamais la qualité. Son libellé est affiché.
5. Aucun placement achetable, aucun lien affilié.
6. L'assistant produit une adéquation, jamais un jugement.
7. Toute règle appliquée au catalogue est publiée dans la page Méthode.
8. Toute décision manuelle est journalisée et publique.

Corollaire structurant. Le tronc pédagogique commun à 80 % est un **veto, pas une précondition**. On regroupe par défaut ; on ne refuse qu'avec la preuve d'une divergence réelle. La formulation inverse — « fusionner si le tronc dépasse 80 % » — rendrait le manque d'information rentable : un organisme qui ne publie pas son programme obtiendrait autant de lignes qu'il a de formules.

2. Les pages

Page	Rôle et mécanique
`/` **Explorer**	La vue principale. Hero avec badge de fraîcheur, recherche à autocomplétion, trois chiffres. Navigation de domaines collante, colonne de filtres collante, liste de cartes. Une fiche s'ouvre en panneau latéral **sans quitter la liste** — mais chaque rangée reste un vrai lien vers `/parcours/<slug>`, donc indexable et ouvrable en nouvel onglet.
`/parcours/$slug` **Fiche**	Page complète d'un parcours, rendue côté serveur : titre, méta-description, canonique auto-référente. C'est la même vue que le panneau latéral, sans son enveloppe.
`/comparer`	Tableau comparatif des parcours sélectionnés. Chaque cellule de coût porte sa condition : comparer 0 € et 1 690 € sans dire que l'un suppose un contrat d'alternance serait trompeur.
`/aide-au-choix`	Assistant d'adéquation. Cinq critères → correspondances et écarts, calculés **entièrement** par `src/modele/adequation.ts`. Le modèle de langage ne sélectionne rien et n'invente aucun écart : il rédige une phrase à partir de listes déjà établies. Sa sortie est vérifiée contre un vocabulaire interdit avant affichage.
`/organismes`	Entrée par organisme plutôt que par parcours, avec le nombre de parcours de chacun.
`/methode`	Toutes les règles appliquées au catalogue, publiées et contestables : classification, regroupement, états d'absence, dérivations, profondeur de vérification, file d'arbitrage. C'est l'invariant 7 rendu visible.
`/admin/seed`	Ingestion réelle, protégée par jeton, refusant d'écraser une base peuplée sans demande explicite.

3. La couche modèle

> Tout `src/modele/` est pur : aucune dépendance à l'interface, aucun accès réseau, testé sans base. C'est là que vivent les règles, et nulle part ailleurs.

Classification

Domaine en 4 niveaux de preuve, **sujet principal** en 4 niveaux avec un seuil de 40 %. L'ordre de déclaration des vocabulaires est **significatif** : la détection retient le premier motif qui correspond, donc réordonner une liste change la classification du catalogue. C'est un changement de règle, à publier et à vérifier par les tests de parité.

Regroupement

Hiérarchie de preuves : programme publié des deux côtés → comparaison réelle du tronc ; suffixe de formule reconnu ; sinon **ambigu**, replié derrière une ancre et signalé, jamais fusionné en silence.

Complétude — six états d'absence

État	Signification	Dénominateur
`renseigne`	Publié par l'organisme	**numérateur**
`derive`	Produit par une règle publiée	**numérateur**
`a_confirmer`	Valeur conservée, non reconfirmée	**dénominateur seul**
`non_communique`	Page lue, l'organisme ne publie pas — **fait sur lui**	**dénominateur seul**
`non_collecte`	Page jamais lue — **fait sur nous**	exclu
`non_applicable`	Le champ n'a pas d'objet ici	exclu
`communique_sur_demande`	Sur devis, jamais publié	exclu

L'asymétrie est le cœur du modèle. Ne jamais faire porter à un organisme une opacité qui est la nôtre. Un échec réseau, une page non lue, un rendu JavaScript qui échoue : tous laissent le champ en `non_collecte`, jamais en « non publié ».

`non_applicable` **exige la lecture de la page ET une règle publiée — les deux.** C'est le seul état qui *ferme* un champ : il sort du dénominateur, sort de la file, et n'est jamais revérifié. Une règle publiée ne suffit pas seule, car les deux règles existantes déduisent depuis un autre champ, potentiellement incomplet sur une fiche jamais lue. Publier une règle la rend contestable, pas vraie.

Coût — deux niveaux obligatoires

Un montant nu ne permet pas de décider : « 0 € » recouvre l'alternance, le compte requis, le certificat payant et l'accès partiel. Toute valeur de coût s'affiche donc avec sa **condition d'obtention**. Quand plusieurs s'appliquent, la plus restrictive pour l'accès l'emporte : un parcours en alternance et éligible CPF affiche la condition d'alternance, parce que c'est elle qui conditionne l'entrée.

Situation	Valeur affichée	Condition
Alternance	Aucun frais pour l'alternant	Sous réserve de signer un contrat
Diplôme public	Frais d'inscription universitaires	Montant fixé par arrêté
Compte requis	Gratuit	Après création d'un compte
Certificat payant	Gratuit à suivre	Certification payante
Freemium	Accès partiel gratuit	Parcours complet payant
Inter-entreprises	(montant)	Tarif par personne, session collective
Intra seul	Réservé aux entreprises	Non accessible à titre individuel

Dérivations — liste fermée

Une dérivation applique une règle de droit publiée, identique pour tous les parcours visés. Ce n'est pas une déduction : elle se conteste **en tant que règle**, jamais en tant que décision. Trois conditions obligatoires : la règle est publiée, la valeur porte l'état `derive`, et la fiche affiche la règle qui l'a produite.

- **Alternance** → coût 0, modalité « pris en charge ». **Bloquée** si l'organisme publie un tarif : INSEEC vend son MSc 8 175 € en initial et le propose aussi en alternance.
- **Déclaration de portée générale** → ORSYS publie que *toutes* ses formations peuvent être organisées en intra. Reportée sur ses fiches, marquée et sourcée.

Provenance — on n'efface pas, on déclasse

> **Incident du 3 août 2026.** Une consigne d'écriture sans règle d'effacement a supprimé **61 prix**, dont trois parcours que Google publie « gratuites ». La consigne avait été appliquée à la lettre, et le résultat était faux.

Règle : une valeur qu'on ne peut pas reconfirmer **ne devient jamais « non communiqué »**. Elle conserve sa valeur, passe en `a_confirmer`, s'affiche signalée, et remonte en tête de file. Seule la lecture d'une page constatant l'absence autorise l'effacement.

Le journal conserve, pour chaque écriture : valeur précédente, nouvelle valeur, URL source, extrait cité, horodatage, origine du changement. **Toute correction de masse est annulable.**

4. Le pipeline de collecte

Découverte

Sitemaps des organismes, via `robots.txt`. 93 organismes sur 143 ayant un domaine au catalogue exposent un sitemap exploitable (65 %). Les URL sont filtrées par pertinence e-commerce puis rapprochées des parcours fichés.

> **Les sitemaps sont un outil de profondeur, jamais de largeur.** La découverte part des domaines connus, donc elle ne peut ramener que des parcours d'organismes connus — les 342 candidats se répartissent sur 54 organismes, tous déjà au catalogue. Les nouveaux acteurs viendront de SIRENE et DREETS, ou de nulle part.

Extraction — la citation obligatoire

Une requête réseau et une requête modèle par page. Chaque valeur extraite s'accompagne de l'extrait littéral du texte source, et **la vérification est programmatique** : on ne demande jamais au modèle s'il a bien cité, on compare la valeur à l'extrait par correspondance de chaîne après normalisation. Un modèle qui s'auto-évalue valide ses propres hallucinations.

Deuxième vérification, moins évidente : **l'extrait doit lui-même figurer dans la page**. Un modèle fabrique une citation aussi facilement qu'une valeur ; sans ancrage dans le texte réellement récupéré, la citation ne prouve rien.

Une liste n'est retenue que si **chaque élément** est attesté : un programme à moitié inventé est pire qu'un programme absent, il a l'air complet.

> « Aucune information déduite » cesse ainsi d'être un principe écrit pour devenir une **contrainte technique**.

Mesures

Mesure	Valeur
Taux de citation valide (lot stratifié figé, 30 pages)	77 – 83 %
Écoles seules — strate la mieux structurée	94 – 97 %
Gain moyen par fiche	4,6 à 8 champs
Extrapolation au catalogue	~1 060 informations, soit 40 % de l'existant

> **Deux règles de mesure.** La ventilation par strate est obligatoire : deux corrections tirant dans des directions opposées s'annulent dans un chiffre global. Et le nombre absolu précède le pourcentage : « 2 rejets sur 11 » se discute, « 69 % » fabrique une fausse précision en cachant la taille de l'échantillon.

Robustesse

- **Politesse** : robots.txt respecté, 1,5 s entre deux requêtes d'un même domaine, le créneau étant réservé *avant* l'attente — sinon la concurrence transforme la cadence en salve.
- **Repli navigateur** : une page dont le texte représente moins de 3 % du HTML servi est presque sûrement rendue côté client. Coursera sert 12 360 caractères pour 890 Ko.
- **Échec ≠ absence** : réseau, rendu, domaine muet — tous laissent le champ en `non_collecte`.
- **Domaine garé** détecté (cas d'un organisme disparu dont le domaine a été repris par un revendeur) et distingué d'un serveur qui refuse simplement notre agent.

Agent de rafraîchissement

Catégorie	Cadence
Universités, diplômes d'État	annuelle
Écoles, bootcamps, organismes déclarés	trimestrielle
Éditeurs, plateformes, indépendants	mensuelle

Déclencheurs événementiels prioritaires sur la cadence : modification signalée par le sitemap, signalement d'utilisateur, revendication de fiche. **Écriture automatique réservée aux valeurs nouvelles et citées** ; toute modification d'une valeur existante passe en validation.

5. Design system

Trois niveaux de jetons dans cet ordre de dépendance : **primitifs** → **sémantiques** → **composants**. Un composant qui a besoin d'une valeur absente ne l'écrit pas en dur : le jeton manquant est ajouté à l'échelle.

Couche	Contenu
Espacement	Base 4 px. Au-delà de 32 px, uniquement les multiples de 8.
Typographie	Échelle de 11 à 48 px. Bricolage Grotesque sur les titres (axe optique `opsz`), Geist sur le texte, DM Mono sur les valeurs chiffrées.
Couleur	Dix paliers par teinte. Neutres froids, **pine** (vérifié), **clay** (absent), **amber** (en attente), crimson (défaillance produit uniquement), accent froid (interactif).
Élévation	Cinq niveaux. L'ombre indique la position dans l'espace, jamais l'importance.
Motion	120 à 280 ms. La sortie est toujours plus rapide que l'entrée.

> **La chrome est achromatique ; la couleur est réservée au sens.** Crimson n'est jamais employé pour qualifier une formation : une information absente n'est pas une erreur, c'est clay. Le rouge dit qu'un chargement a échoué, jamais qu'un organisme ne publie pas son prix.

Composants

OrganizationMark · OrganizationIdentity · SkillTag · MetadataItem · PriceSummary · CertificationBadge · CompletenessIndicator · CatalogFreshnessBadge · SearchField · CompareButton · TrainingResultCard · FilterPanel · FilterAccordion · ActiveFilter · SortSelect · ResultToolbar · EmptyState · ResultSkeleton · PiedFiche

Le code-barres est l'élément signature : un trait par information suivie, plein si renseignée, hachuré si non collectée, effacé si sans objet. Il ne dit rien de la qualité, tout de l'état de la fiche. **Jamais converti en pourcentage** — un chiffre sur 100 se lit comme une note.

6. Garde-fous

Invariants de catalogue — `bun run invariants`

1. Aucune fiche `catalogue_seul` ne porte un champ « non publié »
2. Aucune fiche `detail_verifie` ne porte un champ « non collecté »
3. Toute dérivation renvoie à une règle de la liste fermée
4. Aucun coût dérivé à zéro quand l'organisme publie un tarif
5. **4 bis** — aucune fiche n'*affiche* « aucun frais » avec un tarif publié
6. Toute valeur écrite par le pipeline porte une citation
7. Aucun coût à zéro sans qualification de sa gratuité
8. Le dénominateur exclut les trois états sans objet

9. Toute fiche possède une URL de site officiel
10. Aucune valeur effacée sans passage par « à confirmer »
11. Aucun `non_applicable` sans lecture de page ET règle publiée

Invariants de design — `bun run invariants:design`

Couleur littérale · dimension hors échelle · durée littérale · syntaxe de variable invalide.

Invariants de rendu — `bun run invariants:rendu` (Playwright)

Écart réel entre éléments de texte adjacents · appartenance des tailles rendues à l'échelle · contraste AA · pied de panneau ancré · liste de suggestions dans la fenêtre.

Ils tournent **avant chaque poussée** via un crochet Git, jamais automatiquement sur la production : ils existent pour attraper une régression avant déploiement, pas pour constater qu'elle est en ligne.

Le motif qui s'est répété six fois. Plafond de découverte, créneau de cadence, garde-fou contourné par l'affichage, `non_applicable` déduit, syntaxe de variable Tailwind, migration non appliquée. À chaque fois : **la règle est juste, la donnée est juste, une couche en aval passe à côté. Rien ne plante, aucun test ne rougit, le résultat est faux.**

Deux conséquences : écrire les invariants sur ce que l'*interface rend*, pas sur ce que le modèle calcule ; et demander à voir des cas réels plutôt qu'un compte-rendu de tests — c'est l'exigence de voir cinq cas concrets qui a fait sortir un défaut pendant que 176 tests étaient au vert.

7. Pistes fermées, avec leur mesure

> Une piste fermée sans son chiffre se rouvre toujours.

Voie	Résultat	Pourquoi
Appariement par score de mots d'URL	58 / 232 — 25 %	À seuil 0,4 on obtiendrait 279 rapprochements, mais l'exemple type rapproche deux diplômes différents. Le seuil reste à 0,6.
Appariement par libellé de lien exact	+1	Les pages catalogue rendent bien des liens, mais l'égalité exacte entre titre fiché et libellé publié ne se produit presque jamais.
Appariement par URL déjà fichée	plafond de 4	Le champ `url` est un domaine d'organisme, pas une adresse de parcours.
Appariement par domaine inféré	5, dont ≥3 faux	Le domaine de la page est inféré depuis des mots d'URL, pas constaté. Même vice qu'un `non_applicable` déduit.
Découverte par comparatifs tiers	79 % de recouvrement	Épuisée. Et aucune donnée n'en est reprise — invariant 5.
DREETS par dénomination sociale	11 / 165 726	Dont la moitié de faux positifs. Le ciblage NAF via SIRENE reste nécessaire.

Conclusion structurelle : c'est le crawl qui débloque l'appariement, pas l'inverse. La quatrième voie — le domaine *constaté* sur la page — exige d'ouvrir la page.

8. Dettes connues, chiffrées

Dette	Chiffre	Note
Fiches sans URL de site officiel	14	Toutes des créateurs indépendants. Plafond déclaré, ne peut que décroître.
Prix déclassés en « à confirmer »	59	Restaurés après l'incident du 3 août, en attente de reconfirmation.
Éligibilité CPF non tranchée	164	Le booléen ne distingue pas « vérifié non éligible » de « non vérifié ».
Profondeur du catalogue	6 / 232	Bloquée par l'appariement.
Intitulés désignant une famille	~17	Non traités par motif : seule la lecture tranche.
Règles lieu et paiement suspendues	165 champs	Elles déduisent depuis un autre champ ; après le crawl, l'entrée sera constatée.
Fonction d'enregistrement	—	Décision produit en attente : le produit n'a ni comptes ni favoris.

9. Chantier suivant — conflits internes

Le crawl lira plusieurs pages par organisme et trouvera des contradictions : deux prix, deux durées, deux programmes pour un même parcours. **Ne jamais trancher automatiquement.** Une contradiction interne est une information sur l'organisme — et aucun comparatif affilié ne la relèvera jamais, puisqu'ils reprennent une seule source.

- Conserver chaque valeur, sa citation, l'URL exacte, la date de lecture. État `en_conflit`.
- Hors du numérateur, **maintenu au dénominateur** : l'information existe, elle n'est pas fiable en l'état.
- Afficher les valeurs divergentes avec leur source, jamais un montant arbitraire — le plus bas flatterait l'organisme, le plus haut serait injuste, les deux seraient un jugement.
- File publique dans Méthode, à côté de la file d'arbitrage.
- Distinguer **conflit** et **obsolescence** par les dates de dernière modification du sitemap.
- Prévoir l'origine de la résolution — arbitrage interne ou déclaration d'organisme — pour le jour où un organisme revendiquera sa fiche.

10. Stack et frontière

TanStack Start + React 19 + TypeScript, Tailwind v4, Lovable Cloud pour le backend. Gestionnaire `bun`.

Côté	Périmètre
Nous	Tout `src/`, y compris le `<head>` — ce projet n'a pas d'`index.html`, le head vit dans `src/routes/__root.tsx`. Plus les scripts, tests et invariants.
Lovable	Le schéma de base et ses migrations, les secrets serveur, `vite.config.ts`, le déploiement.
Partagé	`main`. Lovable pousse en direct : `git pull` avant chaque poussée, jamais de réécriture d'historique.

Le schéma précède le code, et c'est mécanique : une colonne manquante produit un message qui la nomme et porte le prompt à envoyer, au lieu d'une erreur 500 muette.

Formlist — dossier technique et produit · état au 4 août 2026 · chiffres lus dans le catalogue au moment de la génération.